Superstore Sales Analysis

End-to-End Retail Sales Analytics and Sales Forecasting

Final Project Presentation

จัดทำโดย

นาย นรภัทร ทะภูมินทร์	**1660702281**
นาย ติณณภพ ออกกิจวัตร	**1660702339**
นาย พิสิษฐ์ สืบสาย	**1660702968**
นาย จีรัฐติกุล ศิริมงคลสันต์	**1660704477**
นาย อนิวัตติ์ สงัดรัมย์	**1660704881**

อาจารย์ที่ปรึกษา

อาจารยศิริญญ์รดา เอกอัครรุ่งโรจน์

หลักสูตรวิทยาศาสตรบัณฑิต

ภาคการศึกษาที่ 2 ปีการศึกษา 2568

ภาควิชาวิทยาการคอมพิวเตอร์ คณะเทคโนโลยีสารสนเทศและนวัตกรรม

มหาวิทยาลัยกรุงเทพ

สารบัญ

บทที่ หน้า

1 บทนำ 1

1.1 ความเป็นมาและความสำคัญของโครงงาน 1

1.2 วัตถุประสงค์ของโครงงาน 1

1.3 คำถามทางธุรกิจ 1

2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง 2

2.1 Data Analytics 2

2.2 CRISP-DM Framework 2

2.3 Machine Learning 2

2.4 งานวิจัยที่เกี่ยวข้อง 2

3 วิธีดำเนินงาน 3

3.1 Dataset Description 3

3.2 Data Preprocessing 3

3.3 Exploratory Data Analysis (EDA) 6

3.4 Machine Learning 10

4 ผลการดำเนินงาน 11

4.1 Machine Learning Result 11

5 อภิปรายผล 12

6 สรุป 13

7 บรรณานุกรม 14

สารบัญภาพ

ภาพที่ หน้า

3.1 ตัวอย่างข้อมูลใน Superstore Dataset 3

3.2 ผลการตรวจสอบชนิดข้อมูลด้วย df.info() 3

3.3 ผลการตรวจสอบ Missing Values 4

3.4 ผลการตรวจสอบ Duplicate Data 4

3.5 ผลการแปลงข้อมูลวันที่ (Date Conversion) 4

3.6 ผลการสร้าง Feature ใหม่ (Feature Engineering) 5

3.7 ผลการลบข้อมูล Outlier 5

3.8 กราฟยอดขายตามประเภทสินค้า (Sales by Category) 6

3.9 กราฟกำไรตามภูมิภาค (Profit by Region) 7

3.10 กราฟความสัมพันธ์ระหว่าง Discount และกำไรเฉลี่ย 8

3.11 กราฟสินค้ายอดขายสูงสุด 10 อันดับ (Top 10 Products by Sales) 9

4.1 ผลลัพธ์จากโมเดล Random Forest Regressor 11

บทที่ 1
บทนำ

1.1 ความเป็นมาและความสำคัญของโครงงาน

ในปัจจุบัน ธุรกิจค้าปลีก (Retail Business) มีการแข่งขันที่สูงขึ้นอย่างต่อเนื่อง ส่งผลให้องค์กรจำเป็นต้องนำข้อมูลมาใช้ในการวิเคราะห์เพื่อสนับสนุนการตัดสินใจทางธุรกิจ การวิเคราะห์ข้อมูล (Data Analytics) จึงกลายเป็นเครื่องมือสำคัญที่ช่วยให้องค์กรสามารถเข้าใจพฤติกรรมของลูกค้า วิเคราะห์แนวโน้มยอดขาย และวางแผนกลยุทธ์ทางธุรกิจได้อย่างมีประสิทธิภาพมากขึ้น

ข้อมูลยอดขายถือเป็นข้อมูลสำคัญที่สามารถสะท้อนพฤติกรรมของลูกค้า ประสิทธิภาพของสินค้า และแนวโน้มทางธุรกิจได้ หากองค์กรสามารถนำข้อมูลดังกล่าวมาวิเคราะห์ได้อย่างถูกต้อง จะช่วยให้สามารถวางแผนด้านการตลาด การบริหารสินค้า และการจัดการต้นทุนได้ดียิ่งขึ้น

ดังนั้น ผู้จัดทำจึงมีความสนใจที่จะวิเคราะห์ข้อมูลยอดขายจาก Superstore Dataset โดยใช้กระบวนการ Data Analytics และ Machine Learning เพื่อค้นหา Insight ที่สำคัญจากข้อมูล และช่วยสนับสนุนการตัดสินใจทางธุรกิจ

1.2 วัตถุประสงค์ของโครงงาน

1. เพื่อวิเคราะห์ข้อมูลยอดขายของธุรกิจค้าปลีก
2. เพื่อศึกษาความสัมพันธ์ระหว่างยอดขาย กำไร และส่วนลด
3. เพื่อค้นหา Insight ที่สามารถช่วยในการตัดสินใจทางธุรกิจ
4. เพื่อสร้างโมเดล Machine Learning สำหรับพยากรณ์ยอดขาย

1.3 คำถามทางธุรกิจ

1. สินค้าประเภทใดสร้างยอดขายสูงที่สุด
2. ภูมิภาคใดสร้างกำไรสูงที่สุด
3. ส่วนลดมีผลต่อกำไรหรือไม่
4. สามารถใช้ Machine Learning พยากรณ์ยอดขายได้หรือไม่

บทที่ 2
ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 Data Analytics

Data Analytics คือกระบวนการวิเคราะห์ข้อมูลเพื่อค้นหารูปแบบ แนวโน้ม และ Insight ที่ซ่อนอยู่ภายในข้อมูล โดยมีเป้าหมายเพื่อสนับสนุนการตัดสินใจทางธุรกิจ กระบวนการดังกล่าวประกอบด้วยการรวบรวมข้อมูล การทำความสะอาดข้อมูล การวิเคราะห์ข้อมูล และการสรุปผลลัพธ์เพื่อใช้ในการตัดสินใจ

Data Analytics ถูกนำมาใช้อย่างแพร่หลายในธุรกิจค้าปลีก เนื่องจากสามารถช่วยวิเคราะห์ยอดขาย พฤติกรรมลูกค้า และประสิทธิภาพของสินค้าในแต่ละประเภทได้

2.2 CRISP-DM Framework

CRISP-DM (Cross Industry Standard Process for Data Mining) เป็นกระบวนการมาตรฐานสำหรับการทำ Data Mining และ Data Analytics ซึ่งได้รับความนิยมอย่างแพร่หลาย ประกอบด้วย 6 ขั้นตอน ได้แก่

1. Business Understanding
2. Data Understanding
3. Data Preparation
4. Modeling
5. Evaluation
6. Deployment

โครงงานนี้ได้นำ CRISP-DM มาใช้เป็นแนวทางในการดำเนินงานทั้งหมด

2.3 Machine Learning

Machine Learning เป็นเทคนิคที่ช่วยให้คอมพิวเตอร์สามารถเรียนรู้จากข้อมูลและพยากรณ์ผลลัพธ์ได้โดยอัตโนมัติ ในโครงงานนี้ได้เลือกใช้ Random Forest Regressor ซึ่งเป็นอัลกอริทึมที่เหมาะสำหรับการพยากรณ์ข้อมูลเชิงตัวเลข และสามารถจัดการข้อมูลที่มีความซับซ้อนได้ดี

Random Forest ทำงานโดยสร้าง Decision Tree หลายต้น และนำผลลัพธ์มาหาค่าเฉลี่ยเพื่อเพิ่มความแม่นยำในการพยากรณ์

2.4 งานวิจัยที่เกี่ยวข้อง

งานวิจัยด้าน Retail Analytics พบว่าการวิเคราะห์ข้อมูลยอดขายสามารถช่วยให้องค์กรเข้าใจแนวโน้มทางธุรกิจและพฤติกรรมของลูกค้าได้ดีขึ้น นอกจากนี้ยังสามารถช่วยเพิ่มประสิทธิภาพในการวางแผนสินค้า การบริหารต้นทุน และการกำหนดกลยุทธ์ทางการตลาด

การใช้ Machine Learning ในการพยากรณ์ยอดขายยังช่วยให้องค์กรสามารถวางแผนธุรกิจในอนาคตได้อย่างมีประสิทธิภาพมากขึ้น

บทที่ 3
วิธีดำเนินงาน

3.1 Dataset Description

Dataset ที่ใช้ในโครงงานนี้คือ Superstore Dataset จาก Kaggle ซึ่งเป็นข้อมูลยอดขายของร้านค้าปลีก ประกอบด้วยข้อมูลสำคัญ เช่น ยอดขาย (Sales) กำไร (Profit) ส่วนลด (Discount) ประเภทสินค้า (Category) และภูมิภาค (Region)

Dataset ประกอบด้วยข้อมูลจำนวน 9,994 แถว และ 21 คอลัมน์

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5
6 df = pd.read_csv('/content/Test.csv', encoding='latin1')
7
8 df.head()
```

	Row ID	Order ID	Order Date	Ship Date	Ship Mode	Customer ID	Customer Name	Segment	Country	City	...	Postal Code	Region	Product ID	Category	Sub-Category	Product Name	Sales	Quantity	Discount	Profit
0	1	CA-2016-152156	11/8/2016	11/11/2016	Second Class	CG-12520	Claire Gute	Consumer	United States	Henderson	...	42420	South	FUR-BO-10001798	Furniture	Bookcases	Bush Somerset Collection Bookcase	261.9600	2	0.00	41.9136
1	2	CA-2016-152156	11/8/2016	11/11/2016	Second Class	CG-12520	Claire Gute	Consumer	United States	Henderson	...	42420	South	FUR-CH-10000454	Furniture	Chairs	Hon Deluxe Fabric Upholstered Stacking Chairs,...	731.9400	3	0.00	219.5820
2	3	CA-2016-138688	6/12/2016	6/16/2016	Second Class	DV-13045	Darrin Van Huff	Corporate	United States	Los Angeles	...	90036	West	OFF-LA-10000240	Office Supplies	Labels	Self-Adhesive Address Labels for Typewriters b...	14.6200	2	0.00	6.8714
3	4	US-2015-108966	10/11/2015	10/18/2015	Standard Class	SO-20335	Sean O'Donnell	Consumer	United States	Fort Lauderdale	...	33311	South	FUR-TA-10000577	Furniture	Tables	Bretford CR4500 Series Slim Rectangular Table	957.5775	5	0.45	-383.0310
4	5	US-2015-108966	10/11/2015	10/18/2015	Standard Class	SO-20335	Sean O'Donnell	Consumer	United States	Fort Lauderdale	...	33311	South	OFF-ST-10000760	Office Supplies	Storage	Eldon Fold 'N Roll Cart System	22.3680	2	0.20	2.5164

5 rows × 21 columns

ภาพที่ 3.1 ตัวอย่างข้อมูลใน Superstore Dataset

3.2 Data Preprocessing

3.2.1 การตรวจสอบข้อมูลเบื้องต้น

ได้ทำการตรวจสอบชนิดข้อมูลด้วยคำสั่ง df.info() เพื่อศึกษาประเภทของข้อมูลในแต่ละ Column

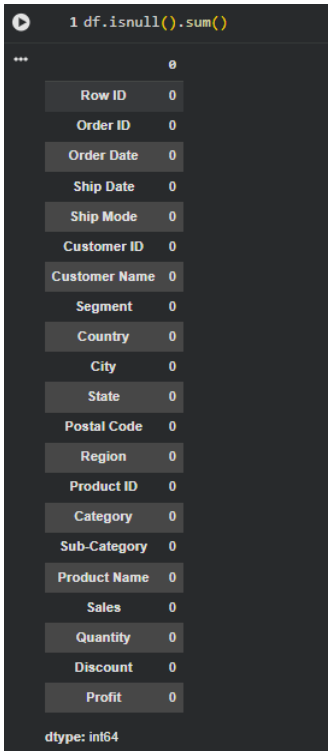
```
1 df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 9975 entries, 0 to 9993
Data columns (total 23 columns):
 #   Column         Non-Null Count  Dtype
---  ------         --------------  -----
 0   Row ID         9975 non-null   int64
 1   Order ID       9975 non-null   object
 2   Order Date     9975 non-null   datetime64[ns]
 3   Ship Date      9975 non-null   datetime64[ns]
 4   Ship Mode      9975 non-null   object
 5   Customer ID    9975 non-null   object
 6   Customer Name  9975 non-null   object
 7   Segment        9975 non-null   object
 8   Country        9975 non-null   object
 9   City           9975 non-null   object
 10  State          9975 non-null   object
 11  Postal Code    9975 non-null   int64
 12  Region         9975 non-null   object
 13  Product ID     9975 non-null   object
 14  Category       9975 non-null   object
 15  Sub-Category   9975 non-null   object
 16  Product Name   9975 non-null   object
 17  Sales          9975 non-null   float64
 18  Quantity       9975 non-null   int64
 19  Discount       9975 non-null   float64
 20  Profit         9975 non-null   float64
 21  Year           9975 non-null   int32
 22  Month          9975 non-null   int32
dtypes: datetime64[ns](2), float64(3), int32(2), int64(3), object(13)
memory usage: 1.8+ MB
```

ภาพที่ 3.2 ผลการตรวจสอบชนิดข้อมูลด้วย df.info()

3.2.2 การตรวจสอบ Missing Values

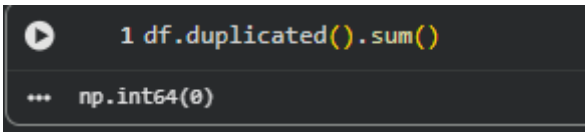
ได้ทำการตรวจสอบข้อมูลสูญหายด้วยคำสั่ง df.isnull().sum() พบว่าไม่มี Missing Values ในทุก Column



ภาพที่ 3.3 ผลการตรวจสอบ Missing Values

3.2.3 การตรวจสอบ Duplicate Data

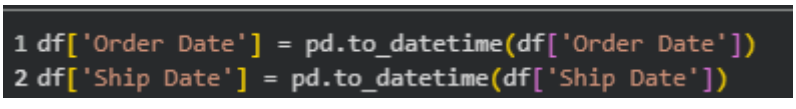
ได้ทำการตรวจสอบข้อมูลซ้ำด้วยคำสั่ง df.duplicated().sum() พบว่าไม่มีข้อมูลซ้ำที่ส่งผลต่อการวิเคราะห์



ภาพที่ 3.4 ผลการตรวจสอบ Duplicate Data

3.2.4 การแปลงข้อมูลวันที่ (Date Conversion)

ผู้จัดทำได้ทำการแปลงข้อมูลประเภทวันที่ ได้แก่ Order Date และ Ship Date ให้อยู่ในรูปแบบ DateTime ด้วยคำสั่ง pd.to_datetime() เพื่อให้สามารถนำข้อมูลไปวิเคราะห์ตามช่วงเวลาได้



ภาพที่ 3.5 ผลการแปลงข้อมูลวันที่ (Date Conversion)

3.2.5 Feature Engineering

ได้สร้าง Feature ใหม่ ได้แก่ Year และ Month จากข้อมูล Order Date เพื่อใช้ในการวิเคราะห์ยอดขายตามช่วงเวลา

```
df['Year'] = df['Order Date'].dt.year
df['Month'] = df['Order Date'].dt.month
```

ภาพที่ 3.6 ผลการสร้าง Feature ใหม่ (Feature Engineering)

3.2.6 Outlier Removal

ในการวิเคราะห์ข้อมูล พบว่ามีข้อมูลบางส่วนที่มียอดขาย (Sales) สูงผิดปกติเมื่อเทียบกับข้อมูลส่วนใหญ่ ซึ่งอาจส่งผลกระทบต่อประสิทธิภาพของ Machine Learning Model จึงได้ทำการลดผลกระทบของ Outlier โดยเลือกเฉพาะข้อมูลที่มียอดขายต่ำกว่า 5000 เหมาะกับ พฤติกรรมการขายทั่วไปมากขึ้น

```
# Remove outliers
df = df[df['Sales'] < 5000]
```

ภาพที่ 3.7 ผลการลบข้อมูล Outlier

3.3 Exploratory Data Analysis (EDA)

3.3.1 Sales by Category

จากการวิเคราะห์ยอดขายตามประเภทสินค้า พบว่า Category ประเภท Furniture มียอดขายรวมสูงที่สุด รองลงมาคือ Technology และ Office Supplies ตามลำดับ

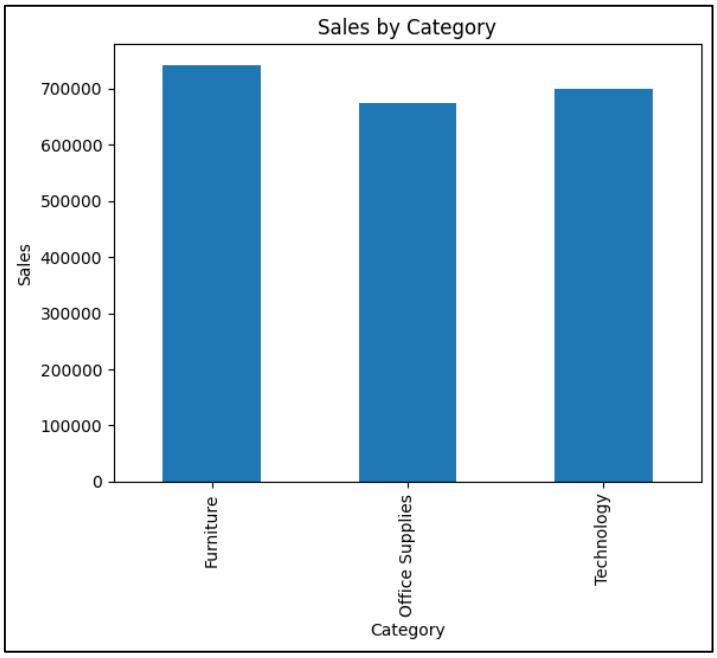
ผลการวิเคราะห์แสดงให้เห็นว่าสินค้ากลุ่ม Furniture และ Technology เป็นกลุ่มสินค้าที่สร้างรายได้หลักให้กับธุรกิจ ขณะที่ Office Supplies มียอดขายต่ำกว่าอีกสองหมวดสินค้า

Insight

- Furniture เป็นหมวดสินค้าที่มียอดขายสูงที่สุด
- Technology มียอดขายใกล้เคียงกับ Furniture
- Office Supplies มียอดขายต่ำที่สุดในทั้ง 3 หมวดสินค้า

Business Decision

- บริษัทควรเพิ่มการลงทุนด้านการตลาดในหมวด Furniture และ Technology
- ควรวางแผนบริหาร Stock สินค้าในหมวดที่มียอดขายสูงให้เพียงพอ
- Office Supplies อาจต้องใช้กลยุทธ์ส่งเสริมการขายเพิ่มเติมเพื่อเพิ่มยอดขายในอนาคต



ภาพที่ 3.8 กราฟยอดขายตามประเภทสินค้า (Sales by Category)

3.3.2 Profit by Region

จากการวิเคราะห์กำไรตามภูมิภาค พบว่า West Region เป็นภูมิภาคที่สร้างกำไรสูงที่สุด รองลงมาคือ East, South และ Central ตามลำดับ

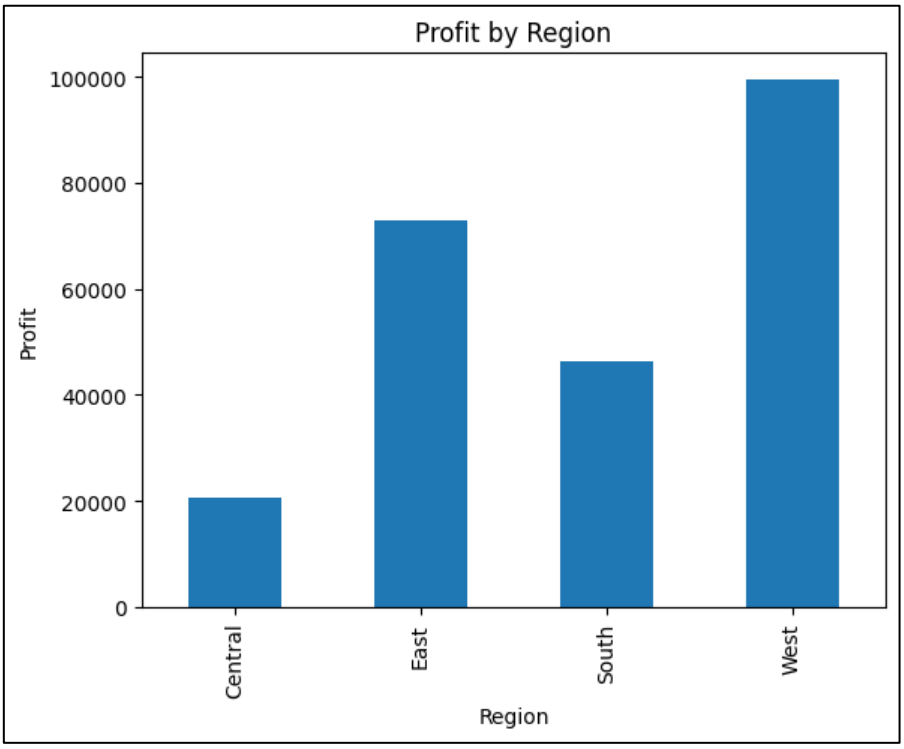
ผลการวิเคราะห์แสดงให้เห็นว่า West Region มีประสิทธิภาพในการสร้างกำไรสูงกว่าภูมิภาคอื่นอย่างชัดเจน ขณะที่ Central Region มีกำไรต่ำที่สุดเมื่อเปรียบเทียบกับทุกภูมิภาค

Insight

- West Region เป็นภูมิภาคที่สร้างกำไรสูงที่สุด
- East Region มีกำไรอยู่ในระดับสูงเช่นกัน
- Central Region มีกำไรต่ำที่สุด

Business Decision

- บริษัทควรขยายตลาดและเพิ่มการลงทุนใน West Region
- ควรวิเคราะห์ปัจจัยที่ทำให้ Central Region มีกำไรต่ำ เพื่อปรับปรุงกลยุทธ์ทางธุรกิจ
- สามารถนำแนวทางการดำเนินงานของ West Region ไปประยุกต์ใช้กับภูมิภาคอื่นเพื่อเพิ่มกำไรในอนาคต



ภาพที่ 3.9 กราฟกำไรตามภูมิภาค (Profit by Region)

3.3.3 Average Profit by Discount

จากการวิเคราะห์ความสัมพันธ์ระหว่างส่วนลด (Discount) และกำไรเฉลี่ย (Average Profit) พบว่าเมื่อมีการให้ส่วนลดในระดับสูง กำไรเฉลี่ยของบริษัทมีแนวโน้มลดลงอย่างชัดเจน และบางช่วงส่วนลดส่งผลให้กำไรติดลบ

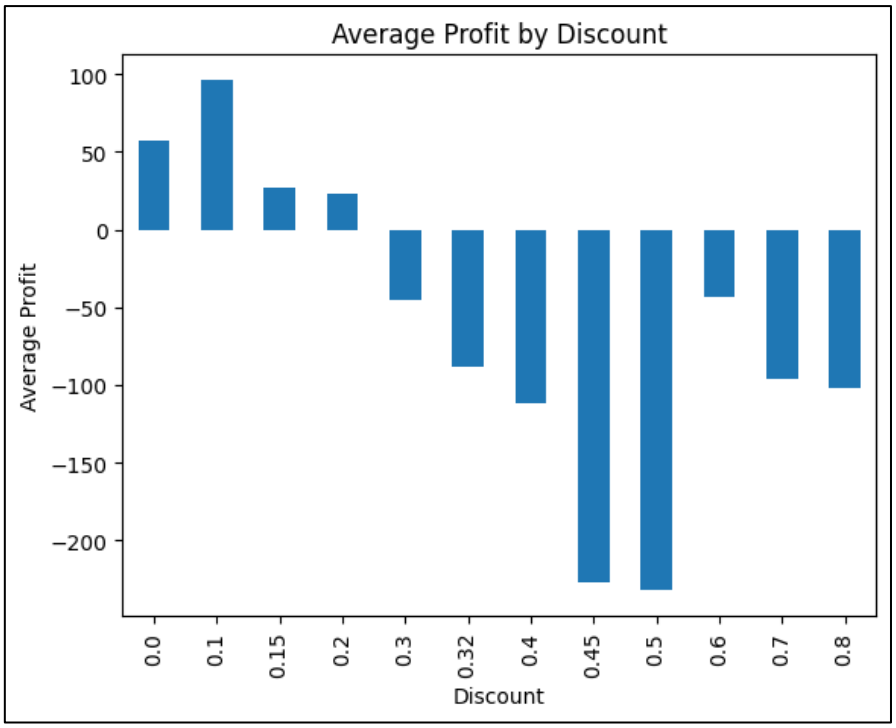
ผลการวิเคราะห์แสดงให้เห็นว่าการให้ส่วนลดสูงเกินไปส่งผลกระทบต่อผลกำไรของธุรกิจ โดยเฉพาะส่วนลดระดับ 0.45 ขึ้นไปที่พบว่ากำไรเฉลี่ยติดลบอย่างชัดเจน

Insight

- ส่วนลดที่สูงส่งผลให้กำไรเฉลี่ยลดลง
- ส่วนลดระดับสูงอาจทำให้ธุรกิจขาดทุน
- ส่วนลดระดับต่ำมีแนวโน้มสร้างกำไรได้ดีกว่า

Business Decision

- บริษัทควรกำหนดขีดจำกัดของส่วนลดสินค้า
- ควรวิเคราะห์โปรโมชั่นก่อนนำไปใช้งานจริง
- สามารถใช้ส่วนลดเฉพาะช่วงเวลาหรือสินค้าที่เหมาะสมเพื่อรักษาระดับกำไรของธุรกิจ



ภาพที่ 3.10 กราฟความสัมพันธ์ระหว่าง Discount และกำไรเฉลี่ย

3.3.4 Top 10 Products by Sales

จากการวิเคราะห์สินค้าที่มียอดขายสูงสุด 10 อันดับ พบว่า HON 5400 Series Task Chairs for Big and Tall เป็นสินค้าที่มียอดขายสูงที่สุด รองลงมาคือ GBC DocuBind TL300 Electric Binding System และ Martin Yale Chadless Opener Electric Letter Opener

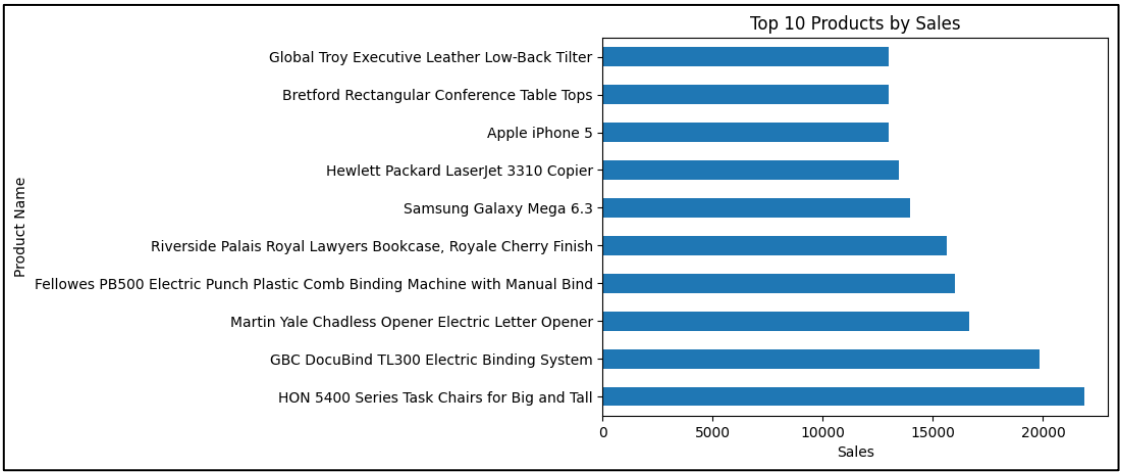
ผลการวิเคราะห์แสดงให้เห็นว่าสินค้าบางประเภทสามารถสร้างยอดขายได้สูงกว่าสินค้าอื่นอย่างชัดเจน ซึ่งสะท้อนถึงความนิยมของลูกค้าและศักยภาพในการสร้างรายได้ของสินค้าแต่ละประเภท

Insight

- HON 5400 Series Task Chairs for Big and Tall มียอดขายสูงที่สุด
- สินค้ากลุ่ม Office Equipment และ Furniture มีหลายรายการติดอันดับยอดขายสูง
- สินค้าบางรายการสามารถสร้างรายได้หลักให้กับธุรกิจได้อย่างชัดเจน

Business Decision

- บริษัทควรเพิ่ม Stock สำหรับสินค้าที่มียอดขายสูง
- สามารถใช้สินค้าขายดีเป็น Hero Product ในการทำโปรโมชั่น
- ควรวิเคราะห์ปัจจัยความสำเร็จของสินค้าขายดีเพื่อนำไปพัฒนากลยุทธ์การขายในอนาคต



ภาพที่ 3.11 กราฟสินค้ายอดขายสูงสุด 10 อันดับ (Top 10 Products by Sales)

3.4 Machine Learning

โครงงานนี้ใช้ Random Forest Regressor สำหรับพยากรณ์ยอดขาย (Sales) โดยใช้เทคนิค Machine Learning แบบ Regression เพื่อวิเคราะห์และคาดการณ์ยอดขายจากข้อมูลธุรกิจ

Features ที่ใช้ในการสร้างโมเดล

- Quantity
- Discount
- Profit
- Category
- Sub-Category
- Region
- Segment
- Ship Mode
- Year
- Month

Target

- Sales

ก่อนทำการสร้างโมเดล ผู้จัดทำได้ทำการแปลงข้อมูลประเภทข้อความ (Categorical Data) ให้อยู่ในรูปแบบตัวเลขด้วยเทคนิค One-Hot Encoding โดยใช้ pd.get_dummies() เพื่อให้ Machine Learning สามารถประมวลผลข้อมูลได้

จากนั้นได้แบ่งข้อมูลออกเป็น Training Set และ Testing Set ในอัตราส่วน 80:20 โดยใช้ train_test_split() เพื่อใช้ในการฝึกโมเดลและประเมินประสิทธิภาพของโมเดล

นอกจากนี้ ยังได้ทำการลดผลกระทบของ Outlier ด้วยการเลือกเฉพาะข้อมูลที่มียอดขายต่ำกว่า 5000 เพื่อช่วยให้โมเดลสามารถเรียนรู้รูปแบบข้อมูลส่วนใหญ่ได้อย่างมีประสิทธิภาพมากขึ้น

ในการพัฒนาโมเดล ผู้จัดทำได้เลือกใช้ Random Forest Regressor เนื่องจากเป็นอัลกอริทึมที่สามารถจัดการข้อมูลที่มีความซับซ้อนได้ดี และช่วยลดปัญหา Overfitting ได้

พร้อมทั้งมีการปรับแต่ง Hyperparameters เช่น:

- n_estimators
- max_depth
- random_state

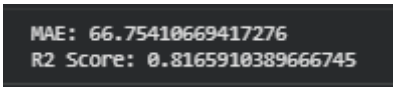
เพื่อเพิ่มประสิทธิภาพในการพยากรณ์ยอดขาย

บทที่ 4
ผลการดำเนินงาน

4.1 Machine Learning Result

ผลการทดลอง Machine Learning Model มีดังนี้

Metric	Result
MAE	66.75
R^2 Score	0.816



ภาพที่ 4.1 ผลลัพธ์จากโมเดล Random Forest Regressor

ผลลัพธ์ดังกล่าวแสดงให้เห็นว่าโมเดลสามารถพยากรณ์ยอดขายได้อย่างมีประสิทธิภาพ และสามารถอธิบายข้อมูลยอดขายได้ประมาณ 81.6% ซึ่งถือว่าอยู่ในระดับที่ดีสำหรับงานวิเคราะห์ข้อมูลทางธุรกิจ

ค่า MAE ที่ลดลงแสดงให้เห็นว่าโมเดลมีความคลาดเคลื่อนในการพยากรณ์ลดลง ขณะที่ค่า R^2 Score ที่สูงขึ้นสะท้อนว่าโมเดลสามารถเรียนรู้รูปแบบของข้อมูลได้ดีขึ้นหลังจากทำ Data Preprocessing, Feature Engineering และ Outlier Removal

นอกจากนี้ การปรับแต่ง Hyperparameters ของ Random Forest Regressor ยังช่วยเพิ่มประสิทธิภาพของโมเดลในการพยากรณ์ยอดขายได้อย่างชัดเจน

บทที่ 5
อภิปรายผล

จากผลการวิเคราะห์ข้อมูลพบว่า Category ประเภท Furniture และ Technology เป็นหมวดสินค้าที่สามารถสร้างยอดขายได้สูงที่สุด ซึ่งสะท้อนให้เห็นว่าสินค้าในกลุ่มดังกล่าวเป็นสินค้าหลักที่ช่วยสร้างรายได้ให้กับธุรกิจ

ในด้านกำไร พบว่า West Region เป็นภูมิภาคที่สร้างกำไรสูงที่สุด ขณะที่ Central Region มีกำไรต่ำที่สุด ซึ่งอาจเกิดจากความแตกต่างด้านพฤติกรรมลูกค้า การแข่งขันทางธุรกิจ หรือกลยุทธ์การขายในแต่ละพื้นที่

นอกจากนี้ ผลการวิเคราะห์ความสัมพันธ์ระหว่าง Discount และ Profit พบว่าการให้ส่วนลดในระดับสูงส่งผลให้กำไรเฉลี่ยลดลงอย่างชัดเจน และบางกรณีอาจทำให้ธุรกิจขาดทุน ซึ่งแสดงให้เห็นว่าการกำหนดโปรโมชั่นและส่วนลดมีผลต่อผลกำไรของบริษัทโดยตรง

ในส่วนของ Machine Learning พบว่า Random Forest Regressor สามารถพยากรณ์ยอดขายได้อย่างมีประสิทธิภาพ โดยมีค่า R^2 Score เท่ากับ 0.816 ซึ่งแสดงว่าโมเดลสามารถอธิบายข้อมูลยอดขายได้ประมาณ 81.6%

ผลลัพธ์ของโมเดลดีขึ้นอย่างชัดเจนหลังจากทำ Data Preprocessing, Feature Engineering และ Outlier Removal โดยเฉพาะการลดผลกระทบของ Outlier ที่ช่วยให้โมเดลสามารถเรียนรู้รูปแบบข้อมูลได้แม่นยำมากขึ้น

อย่างไรก็ตาม โครงงานนี้ยังมีข้อจำกัดบางประการ เช่น การใช้ข้อมูลจาก Dataset เพียงชุดเดียว และยังไม่ได้พิจารณาปัจจัยภายนอก เช่น ฤดูกาล สภาพเศรษฐกิจ หรือพฤติกรรมลูกค้าในแต่ละช่วงเวลา ซึ่งอาจส่งผลต่อยอดขายของธุรกิจ

ในอนาคต สามารถพัฒนาโครงงานเพิ่มเติมได้โดยใช้ข้อมูลที่มีความหลากหลายมากขึ้น รวมถึงทดลองใช้อัลกอริทึม Machine Learning อื่น ๆ เพื่อเปรียบเทียบประสิทธิภาพและเพิ่มความแม่นยำในการพยากรณ์ยอดขาย

บทที่ 6
สรุป

โครงงานนี้ได้ทำการวิเคราะห์ข้อมูลยอดขายของธุรกิจค้าปลีกโดยใช้กระบวนการ Data Analytics และ Machine Learning เพื่อค้นหา Insight ที่สำคัญจากข้อมูล และสนับสนุนการตัดสินใจทางธุรกิจ

ผู้จัดทำได้ดำเนินงานตามกระบวนการ Data Analytics ตั้งแต่การทำ Data Preprocessing การตรวจสอบ Missing Values และ Duplicate Data การสร้าง Feature ใหม่ รวมถึงการทำ Exploratory Data Analysis (EDA) เพื่อศึกษาความสัมพันธ์และแนวโน้มของข้อมูล

ผลการวิเคราะห์พบว่า Category ประเภท Furniture และ Technology เป็นหมวดสินค้าที่สร้างยอดขายสูงที่สุด ขณะที่ West Region เป็นภูมิภาคที่สร้างกำไรสูงที่สุด นอกจากนี้ยังพบว่าการให้ส่วนลดในระดับสูงส่งผลให้กำไรเฉลี่ยลดลงและอาจทำให้ธุรกิจขาดทุนได้

ในส่วนของ Machine Learning ได้ใช้ Random Forest Regressor สำหรับพยากรณ์ยอดขาย โดยทำการปรับปรุงประสิทธิภาพของโมเดลด้วย Feature Engineering, Outlier Removal และ Hyperparameter Tuning

ผลลัพธ์ของโมเดลมีค่า

MAE = 66.75

R^2 Score = 0.816

ซึ่งแสดงให้เห็นว่าโมเดลสามารถพยากรณ์ยอดขายได้อย่างมีประสิทธิภาพ และสามารถอธิบายข้อมูลยอดขายได้ประมาณ 81.6%

จากผลการดำเนินงาน สามารถสรุปได้ว่าการวิเคราะห์ข้อมูลและ Machine Learning สามารถช่วยสนับสนุนการตัดสินใจทางธุรกิจได้อย่างมีประสิทธิภาพ ทั้งในด้านการวางแผนการตลาด การบริหารสินค้า การควบคุมส่วนลด และการวางแผนยอดขายในอนาคต

บทที่ 7

บรรณานุกรม

Géron, A. (2019). Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow (2nd ed.) . O'Reilly Media

Han, J., Kamber, M., & Pei, J. (2011). Data mining: Concepts and techniques (3rd ed.). Morgan Kaufmann.

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. In Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining (pp. 29–39).

Chowdhury, V. (2021). Superstore dataset. Kaggle. https://www.kaggle.com/datasets/vivek468/superstore-dataset-final

Scikit-learn developers. (2024). Scikit-learn documentation. https://scikit-learn.org/

The pandas development team. (2024). Pandas documentation. https://pandas.pydata.org/